

Laporan Tugas UAS Mata Kuliah Pembelajaran Mesin
“Sentiment Analysis of Hotel Reviews Using Support Vector Machine”



Kelompok 20 :

- 1. Filzah Syakirah (502320010200)**
- 2. Dian Pratiwi (187221020)**

Dosen Pengampu :

Dr. Rimuljo Hendradi, S.Si., MSi.

Program Studi S1 – Sistem Informasi

Fakultas Sains dan Teknologi

Universitas Airlangga

Surabaya

2024

Daftar Isi

Daftar Isi.....	i
Daftar Gambar.....	ii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Tujuan.....	2
1.3 Manfaat.....	2
BAB II DASAR TEORI.....	3
2.1 Ulasan Daring.....	3
2.2 Hotel	3
2.3 Analisis Sentimen.....	3
2.4 Support Vector Machine (SVM).....	3
BAB III METODOLOGI PENELITIAN	5
3.1 Dataset.....	5
3.2 Langkah Metodologi	6
3.3 Langkah – Langkah Melakukan Pra Pemrosesan Data	8
3.4 Langkah – Langkah Melakukan Metode SVM, LogisticRegression, dan NaiveBayes 11	11
BAB IV UJI COBA DAN PEMBAHASAN.....	15
4.1 Perbandingan Hasil Setiap Percobaan.....	15
4.2 Analisa Masalah	16
4.3 Solusi Permasalahan.....	16
BAB V KESIMPULAN DAN SARAN.....	18
5.1 Kesimpulan.....	18
5.2 Saran.....	18
DAFTAR PUSTAKA.....	19

Daftar Gambar

Gambar 3.1 Dataset.....	5
Gambar 3.2 Metodologi Penelitian.....	6

BAB I

PENDAHULUAN

1.1 Latar Belakang

Dalam era digital saat ini, internet dimanfaatkan di berbagai bidang, seperti media untuk mendapatkan informasi, menjalankan bisnis, mendapatkan hiburan, hingga mengakses media sosial. Banyak orang menggunakan internet untuk mempermudah berbagai aktivitas, salah satunya adalah untuk memperoleh informasi terkait ulasan hotel. Semakin banyaknya hotel yang dapat dituju saat berpergian sering kali membuat calon pengunjung kebingungan untuk menentukan hotel mana yang cocok untuk mereka kunjungi.

Ulasan online memainkan peran penting dalam membentuk persepsi konsumen terhadap suatu produk atau layanan. Salah satu sektor yang sangat dipengaruhi oleh ulasan online adalah industri perhotelan. Ulasan hotel yang tersedia di berbagai platform online, memberikan gambaran tentang pengalaman tamu hotel sebelumnya, baik yang positif maupun negatif. Namun, dengan banyaknya ulasan yang tersedia, sulit bagi calon pengunjung untuk membaca dan menganalisis semua ulasan secara manual.

Teknologi pembelajaran mesin, khususnya analisis sentimen diperlukan untuk memudahkan pelanggan menarik kesimpulan dari data ulasan sehingga mereka dapat memilih hotel dengan tepat. Analisis sentimen adalah teknik pemrosesan bahasa alami (NLP) yang digunakan untuk menentukan sikap atau perasaan penulis terhadap suatu topik, yang dalam hal ini adalah pengalaman mereka menginap di hotel.

Salah satu metode yang umum digunakan untuk analisis sentimen adalah Support Vector Machine (SVM). Support Vector Machine adalah metode klasifikasi yang bekerja dengan cara mencari hyperplane dengan margin terbesar. Hyperplane adalah garis batas pemisah data antar kelas. Margin adalah jarak antara hyperplane dengan data terdekat pada masing-masing kelas. Adapun data terdekat dengan hyperplane pada masing masing kelas inilah yang disebut support vector (J. Yunliang, et al., 2010). SVM bekerja dengan mencari hyperplane terbaik yang memisahkan data ke dalam kelas-kelas yang berbeda, sehingga dapat mengidentifikasi sentimen positif atau negatif dari ulasan dengan akurasi tinggi.

Dengan analisis sentimen menggunakan metode SVM, ulasan hotel dapat dikategorikan secara otomatis berdasarkan sentimen yang terkandung di dalamnya. Hal ini akan sangat membantu calon pengunjung dalam menilai kualitas suatu hotel secara lebih efisien dan akurat, sehingga mereka dapat membuat keputusan yang lebih baik dalam memilih tempat menginap.

1.2 Tujuan

1. Mengembangkan model analisis sentimen menggunakan Support Vector Machine (SVM) untuk mengklasifikasikan ulasan hotel secara otomatis.
2. Mempermudah calon pengunjung hotel dalam mengevaluasi dan memilih hotel berdasarkan ulasan online.
3. Menguji keandalan dan akurasi metode SVM dalam analisis sentimen ulasan hotel.

1.3 Manfaat

1. Bagi Calon Pengunjung Hotel: Mempermudah penilaian dan pemilihan hotel berdasarkan ulasan yang merklasifikasi secara otomatis.
2. Bagi Industri Perhotelan: Memberikan umpan balik untuk meningkatkan layanan berdasarkan analisis sentimen ulasan tamu.
3. Bagi Peneliti: Menambah wawasan tentang penerapan SVM dalam analisis sentimen.
4. Bagi Platform Ulasan Online: Meningkatkan akurasi sistem rekomendasi berbasis sentimen ulasan pengguna.

BAB II

DASAR TEORI

2.1 Ulasan Daring

Ulasan dari hotel adalah salah satu sumber informasi paling terpercaya yang dapat digunakan untuk memahami mengapa tamu puas atau tidak puas karena didasarkan pada pengalaman tamu yang sebenarnya (Gretzel & Yoo, 2008). Menurut (Lee, Park, & Han, 2008) orang akan mempertimbangkan jumlah ulasan sebagai salah satu pertimbangan bahwa barang atau jasa tersebut populer atau bernilai yang nantinya akan berpengaruh pada kemauan untuk membeli barang atau jasa tersebut. Tamu cenderung untuk memberikan evaluasi mengenai kualitas produk dan jasa pada online platforms, dimana menurut survey yang dilakukan lebih dari 70% tamu mempercayai ulasan yang diberikan dan 85% mengatakan bahwa ulasan daring mempengaruhi perilaku dalam melakukan pembelian (Shen, Dai, Wang, & Gou, 2015).

2.2 Hotel

Hotel adalah suatu bentuk akomodasi yang dikelola secara komersial, yang menyediakan layanan penginapan, makanan, minuman, dan fasilitas lainnya bagi tamu yang menginap. Industri perhotelan sangat bergantung pada ulasan daring, karena ulasan ini dapat mempengaruhi reputasi hotel dan tingkat hunian. Hotel-hotel menggunakan ulasan daring sebagai alat untuk memahami keinginan dan kebutuhan tamu serta untuk meningkatkan layanan mereka. Ulasan positif dapat meningkatkan reputasi dan daya tarik hotel, sementara ulasan negatif dapat memberikan masukan yang berharga untuk perbaikan.

2.3 Analisis Sentimen

Menurut Tang dalam Haddi et al (2013,26), analisa sentimen pada review adalah proses menyelidiki review produk di internet untuk menentukan opini atau perasaan terhadap suatu produk secara keseluruhan. Teknik ini sangat berguna dalam mengekstrak informasi berharga dari ulasan pengguna yang sangat banyak dan beragam.

2.4 Support Vector Machine (SVM)

Support Vector Machine adalah metode klasifikasi yang bekerja dengan cara mencari hyperplane dengan margin terbesar. Hyperplane adalah garis batas pemisah data antar kelas. Margin adalah jarak antara hyperplane dengan data terdekat pada masing-masing kelas. Adapun data terdekat dengan hyperplane pada masing masing kelas inilah yang disebut support vector (J. Yunliang, et al., 2010).

Penelitian ini berpusat pada klasifikasi biner yang terdiri dua kelas. Kelas tersebut adalah positif atau negatif. Menurut Patil et al. (2014, 2610), ada beberapa keuntungan Support Vector Machines (SVM), diantaranya:

a. Ruang Input Dimensi Tinggi

Klasifikasi teks harus berurusan dengan banyak fitur (mungkin lebih dari 1000). SVM menggunakan perlindungan tepat yang tidak tergantung pada sejumlah fitur sehingga memiliki kemampuan untuk menangani sejumlah besar fitur.

b. Ruang Dokumen Vektor

Meskipun representasi dimensi tinggi, masing-masing dokumen vektor hanya mengandung beberapa elemen non-zero. Selebihnya masalah kategorisasi teks adalah linear terpisah.

BAB III

METODOLOGI PENELITIAN

3.1 Dataset


Dataset yang digunakan berjudul Trip Advisor Hotel Reviews yang diambil dari situs Kaggle. Dataset ini terdiri dari 20.491 baris dan 2 kolom. Setiap baris ulasan mencakup teks ulasan dan rating yang diberikan oleh pengguna (dari 1 hingga 5) yang dipresentasikan sebagai berikut :

1. Review : Teks ulasan yang diberikan oleh pengguna.
2. Rating : Peringkat yang diberikan pengguna, dalam skala 1 hingga 5.

Review	Rating
nice hotel expensive parking got good deal stay hotel anniversary, arrived late evening took advice	4
ok nothing special charge diamond member hilton decided chain shot 20th anniversary seattle, stay	2
nice rooms not 4* experience hotel monaco seattle good hotel n't 4* level.positives large bathroo	3
unique, great stay, wonderful time hotel monaco, location excellent short stroll main downtown s	5
great stay great stay, went seahawk game awesome, downfall view building did n't complain, room	5
love monaco staff husband stayed hotel crazy weekend attending memorial service best friend hu	5
cozy stay rainy city, husband spent 7 nights monaco early january 2008. business trip chance com	5
excellent staff, housekeeping quality hotel chocked staff make feel home, experienced exceptiona	4
hotel stayed hotel monaco cruise, rooms generous decorated uniquely, hotel remodeled pacific b	5
excellent stayed hotel monaco past w/e delight, reception staff friendly professional room smart	5
poor value stayed monaco seattle july, nice hotel priced 100- 150 night not, hotel takes beating qu	2
nice value seattle stayed 4 nights late 2007. looked comparable hilton marriott westin area points	4
nice hotel good location hotel kimpton design whimsical vibe fun, staff young casual problem hot	4
nice hotel not nice staff hotel lovely staff quite rude, bellhop desk clerk going way make things dif	3
great hotel night quick business trip, loved little touches like goldfish leopard print robe, complain	4
horrible customer service hotel stay february 3rd 4th 2007my friend picked hotel monaco appeali	1
disappointed say anticipating stay hotel monaco based reviews seen tripadvisor, definitely disppc	2

Gambar 3.1 Dataset

3.2 Langkah Metodologi



Gambar 3.2 Metodologi Penelitian

Penelitian ini menerapkan tahapan sistematis yang digambarkan pada Gambar 3.2 untuk menghasilkan nilai klasifikasi yang efektif. Tahapan tersebut terdiri atas:

1. Collecting Data

Data diambil dari situs Kaggle dengan judul "Trip Advisor Hotel Reviews," yang terdiri dari 20.491 ulasan hotel. Dataset ini dipilih karena memiliki karakteristik yang diperlukan untuk analisis sentimen ulasan hotel.

2. Data Preprocessing

Pada tahap ini, data yang diperoleh dibersihkan dan ditransformasi untuk mempermudah identifikasi dan koreksi kesalahan yang dapat mempengaruhi hasil klasifikasi. Tahap ini mencakup:

a. Standardization

Melakukan standarisasi teks ulasan seperti menghapus karakter non-alfabet dan mengonversi semua teks menjadi huruf kecil

b. Stop Words

Menghapus kata-kata yang tidak digunakan yang sering muncul pada data

c. Stemming

Mengubah kata-kata ke bentuk dasarnya.

d. Labeling Data

Memberikan pelabelan pada data berdasarkan peringkat bintang dari setiap data ulasan, jika bintang lebih besar dari atau sama dengan 3, label akan menjadi 1 atau ulasan positif, tetapi jika peringkat kurang dari 3, label akan menjadi 0 atau ulasan negatif.

3. Representasi Data

Pada tahap ini, teks ulasan yang telah diproses akan diubah menjadi bentuk numerik menggunakan metode TF-IDF (Term Frequency-Inverse Document Frequency).

$$W D t = t f d t * I d f t$$

TF-IDF adalah teknik yang mengukur seberapa penting sebuah kata dalam sebuah dokumen relatif terhadap seluruh koleksi dokumen (corpus).

4. Pembagian Data

Setelah data diubah menjadi representasi numerik, data dibagi menjadi dua set: set pelatihan (*training set*) dan set pengujian (*testing set*) dengan rasio 80% untuk pelatihan dan 20% untuk pengujian. Set pelatihan digunakan untuk melatih model machine learning, sementara set pengujian digunakan untuk menguji kinerja model yang telah dilatih.

5. Pelatihan Model

Tahap ini bertujuan untuk melatih berbagai model machine learning menggunakan set data pelatihan untuk menghasilkan model yang mampu mengklasifikasikan ulasan hotel berdasarkan sentimennya. Model yang digunakan yaitu :

a. Naive Bayes: Model probabilistik yang menggunakan teorema Bayes untuk klasifikasi. Model ini sederhana namun efektif untuk banyak tugas klasifikasi teks.

b. Support Vector Machine (SVM): Model yang mencari hyperplane optimal yang memisahkan data dalam ruang fitur dengan margin terbesar. SVM sangat efektif dalam ruang dimensi tinggi dan digunakan untuk klasifikasi teks.

c. Logistic Regression: Model regresi yang digunakan untuk prediksi probabilitas hasil biner. Dalam konteks ini, digunakan untuk menentukan kategori ulasan berdasarkan fitur teks yang diekstraksi.

6. Evaluasi Model

Setelah model dilatih, kinerjanya dievaluasi menggunakan set pengujian. Alat yang digunakan untuk evaluasi adalah confusion matrix.

$$Accuracy = \frac{True\ Positive + True\ Negative}{True\ Positive + True\ Negative + False\ Positive + False\ Negative}$$

$$Recall = \frac{True\ Positive}{True\ Positive + False\ Negative}$$

$$Precision = \frac{True\ Positive}{True\ Positive + False\ Positive}$$

$$F1 - score = 2 * \frac{Precision * Recall}{Precision + Recall}$$

Confusion matrix adalah tabel yang menggambarkan kinerja model klasifikasi dengan menghitung jumlah true positives, true negatives, false positives, dan false negatives. Dari sini, metrik kinerja seperti akurasi, presisi, recall, dan F1-score dapat dihitung untuk memberikan gambaran lengkap tentang seberapa baik model tersebut bekerja.

7. Perbandingan Hasil

Tahap akhir adalah membandingkan hasil dari berbagai model untuk menentukan model mana yang terbaik dalam tugas klasifikasi ulasan. Perbandingan dilakukan berdasarkan metrik evaluasi yang dihasilkan dari confusion matrix. Model dengan kinerja terbaik akan dipilih berdasarkan keseimbangan antara akurasi, presisi, recall, dan F1-score, sehingga memastikan model yang paling efektif dan andal untuk prediksi.

3.3 Langkah – Langkah Melakukan Pra Pemrosesan Data

1. Memuat Data

```
[ ] import pandas as pd
    hotel = pd.read_csv("hotel.csv")
```

Memuat data hotel.csv dengan library pandas

2. Mengimpor library

```
[ ] import nltk #natural language toolkit
    from nltk.stem import PorterStemmer
    nltk.download("stopwords")
    # Initialize Python porter stemmer
    ps = PorterStemmer()
```

```
➡ [nltk_data] Downloading package stopwords to /root/nltk_data...
   [nltk_data] Package stopwords is already up-to-date!
```

Langkah ini mengimpor library yang akan digunakan nantinya.

3. Memulai Pra Pemrosesan Data dengan Cleaning Data

```
# 1. Data cleaning
import string
import re
def clean_data(hotel):
    # Convert text to lowercase
    hotel = hotel.lower() #mengubah tiap kalimat menjadi lowercase ex: GOOD jadi good

    # Remove punctuation
    hotel = hotel.translate(str.maketrans("", "", string.punctuation)) #menghilangkan tanda baca

    # Remove special characters
    hotel = re.sub(r"[^\w\s]", "", hotel)

    # Remove extra whitespace
    hotel = re.sub(r"\s+", " ", hotel) #menghilangkan spasi berlebih

    return hotel

hotel["Review"] = hotel["Review"].apply(clean_data)
```

Pada tahap ini, teks akan diubah menjadi lowercase (GOOD menjadi good) menghilangkan tanda baca dan menghilangkan spasi berlebih.

4. Pra Pemrosesan Tahap Standarisasi

```
[ ] # 2. Standardization
from nltk.corpus import stopwords

def standardize_text(hotel):
    # Convert text to lowercase
    hotel = hotel.lower()

    # Remove stop words
    stop_words = set(stopwords.words("english")) #stopwords : an a the
    hotel = " ".join([word for word in hotel.split() if word not in stop_words]) #selain kata stopwords ga dihilangkan

    return hotel

hotel["Review"] = hotel["Review"].apply(standardize_text)
```

Pada tahap standarisasi, seluruh stop word (seperti a, an, the) dihilangkan.

5. Pra Pemrosesan Tahap Stemming

```
# 3. Stemming
from nltk.stem import PorterStemmer

stemmer = PorterStemmer()
def stem_hotel(hotel):
    # Stem words
    hotel = " ".join([stemmer.stem(word) for word in hotel.split()]) #stemming : running jadi run

    return hotel

hotel["Review"] = hotel["Review"].apply(stem_hotel)

print(hotel['Review'])
```

```
0      nice hotel expens park got good deal stay hote...
1      ok noth special charg diamond member hilton de...
2      nice room 4 experi hotel monaco seattl good ho...
3      uniqu great stay wonder time hotel monaco loca...
4      great stay great stay went seahawk game awesom...
...
20486  best kept secret 3rd time stay charm 5star ca ...
20487  great locat price view hotel great quick place...
20488  ok look nice modern outsid desk staff nt parti...
20489  hotel theft ruin vacat hotel open sept 17 2007...
20490  peopl talk ca nt believ excel rate hotel nt ye...
Name: Review, Length: 20491, dtype: object
```

Pada tahap stemming dilakukan perubahan kata berimbuhan menjadi kata asli itu sendiri. Sebagai contoh adalah kata running menjadi run, imbuhan ing dihilangkan.

6. Pra Pemrosesan Tahap Labelling Data

```
import re
import string

def label_sentiment(Rating):
    """Assigns sentiment score based on rating threshold (customizable)."""
    rating_int = int(Rating)
    sentiment_threshold = 3 # Adjust this threshold as needed
    return 1 if rating_int >= sentiment_threshold else 0

    #lebih dari sama dengan 3 maka dilabelling 1
    #kurang dari 3 maka dilabelling 0

# Assuming you have a DataFrame 'data' with a 'Rating' column

# Clean the "Review" column using the clean_data function
hotel["Review"] = hotel["Review"].apply(clean_data)

# Label sentiment in a new "Sentiment" column using label_sentiment
hotel["Sentiment"] = hotel["Rating"].apply(label_sentiment)

# Print the processed data
print(hotel)

Sentiment=hotel["Sentiment"]
```

Pada tahap labelling data, akan ditambahkan kolom Sentiment yang akan melabel data sesuai dengan hasil rating yang ada di kolom kedua. Jika Rating ≥ 3 maka akan dilabel 1 dan jika rating < 3 maka akan dilabel 0. Hasil labelling data sebagai berikut.

	Review	Rating	Sentiment
0	nice hotel expens park got good deal stay hote...	4	1
1	ok noth special charg diamond member hilton de...	2	0
2	nice room 4 experi hotel monaco seattl good ho...	3	1
3	uniqu great stay wonder time hotel monaco loca...	5	1
4	great stay great stay went seahawk game awesom...	5	1
...	...	...	...
20486	best kept secret 3rd time stay charm 5star ca ...	5	1
20487	great locat price view hotel great quick place...	4	1
20488	ok look nice modern outsid desk staff nt parti...	2	0
20489	hotel theft ruin vacat hotel open sept 17 2007...	1	0
20490	peopl talk ca nt believ excel rate hotel nt ye...	2	0

[20491 rows x 3 columns]

3.4 Langkah – Langkah Melakukan Metode SVM, LogisticRegression, dan NaiveBayes

1. Menghitung Skor TF- IDF

```
#Menghitung skor tf idf
import pandas as pd
from sklearn.feature_extraction.text import TfidfVectorizer

# Create a TfidfVectorizer object
vectorizer = TfidfVectorizer(max_df=0.8, min_df=2, stop_words='english')

# Transform the data into a TF-IDF matrix
tfidf_matrix = vectorizer.fit_transform(hotel['Review'])

# Get the TF-IDF scores for each word
tfidf_scores = tfidf_matrix.toarray()

# Convert the sparse TF-IDF matrix to a dense NumPy array
dense_tfidf_matrix = tfidf_matrix.toarray()

# Print the TF-IDF scores
print(tfidf_scores)

[[0. 0. 0. ... 0. 0. 0.]
 [0. 0. 0. ... 0. 0. 0.]
 [0. 0. 0. ... 0. 0. 0.]
 ...
 [0. 0. 0. ... 0. 0. 0.]
 [0. 0. 0. ... 0. 0. 0.]
 [0. 0. 0. ... 0. 0. 0.]]
```

Pada tahap ini, skor TF IDF dihitung berdasarkan kolom Review yang telah diproses sebelumnya.

2. Metode SVM

a) Kernel linear dengan text size = 0.2 dan random state 10

```
#SVM LINEAR
#pemodelan svm
from sklearn.model_selection import train_test_split
from sklearn.svm import SVC
from sklearn.metrics import classification_report

# Split the data into training and testing sets
X_train, X_test, y_train, y_test = train_test_split(tfidf_matrix, Sentiment, test_size=0.2, random_state=10)

# Create an SVM model
model = SVC(kernel='linear')

# Train the model
model.fit(X_train, y_train)

# Evaluate the model
y_pred = model.predict(X_test)

from sklearn.metrics import accuracy_score
from sklearn.metrics import classification_report
print("pemodelan SVM".center(75, '='))

print('CLASSIFICATION REPORT SVM'.center(75, '='))
print(classification_report(y_test, y_pred))
```

Pada tahap ini, dilakukan splitting data dengan text size = 0.2 dan random state 10. X merupakan skor TF IDF dan y merupakan kolom sentiment yang ditambahkan sebelumnya. Lalu pengklasifikasian menggunakan Metode SVM dengan kernel = linear. Berikut merupakan classification reportnya.

```

=====pemodelan SVM=====
=====CLASSIFICATION REPORT SVM=====

```

	precision	recall	f1-score	support
0	0.81	0.71	0.76	629
1	0.95	0.97	0.96	3470
accuracy			0.93	4099
macro avg	0.88	0.84	0.86	4099
weighted avg	0.93	0.93	0.93	4099

b) Kernel RBF dengan dengan text size = 0.2 dan random state 10

```

#SVM LINEAR
#pemodelan svm
from sklearn.model_selection import train_test_split
from sklearn.svm import SVC
from sklearn.metrics import classification_report

# Split the data into training and testing sets
X_train, X_test, y_train, y_test = train_test_split(tfidf_matrix, Sentiment, test_size=0.2, random_state=10)

# Create an SVM model
model = SVC(kernel='rbf')

# Train the model
model.fit(X_train, y_train)

# Evaluate the model
y_pred = model.predict(X_test)

from sklearn.metrics import accuracy_score
from sklearn.metrics import classification_report
print("pemodelan SVM".center(75,'='))

print('CLASSIFICATION REPORT SVM'.center(75,'='))
print(classification_report(y_test, y_pred))

```

Pada tahap ini, dilakukan splitting data dengan text size = 0.2 dan random state 10. X merupakan skor TF IDF dan y merupakan kolom sentiment yang ditambahkan sebelumnya. Lalu pengklasifikasian menggunakan Metode SVM dengan kernel = RBF. Berikut merupakan classification reportnya.

```

=====pemodelan SVM=====
=====CLASSIFICATION REPORT SVM=====

```

	precision	recall	f1-score	support
0	0.84	0.66	0.74	629
1	0.94	0.98	0.96	3470
accuracy			0.93	4099
macro avg	0.89	0.82	0.85	4099
weighted avg	0.93	0.93	0.93	4099

c) Kernel sigmoid dengan dengan text size = 0.2 dan random state 10

```
#SVM LINEAR
#pemodelan svm
from sklearn.model_selection import train_test_split
from sklearn.svm import SVC
from sklearn.metrics import classification_report

# Split the data into training and testing sets
X_train, X_test, y_train, y_test = train_test_split(tfidf_matrix, Sentiment, test_size=0.3, random_state=10)

# Create an SVM model
model = SVC(kernel='sigmoid')

# Train the model
model.fit(X_train, y_train)

# Evaluate the model
y_pred = model.predict(X_test)

from sklearn.metrics import accuracy_score
from sklearn.metrics import classification_report
print("pemodelan SVM".center(75,'='))

print('CLASSIFICATION REPORT SVM'.center(75,'='))
print(classification_report(y_test, y_pred))
```

Pada tahap ini, dilakukan splitting data dengan text size = 0.2 dan random state 10. X merupakan skor TF IDF dan y merupakan kolom sentiment yang ditambahkan sebelumnya. Lalu pengklasifikasian menggunakan Metode SVM dengan kernel = sigmoid. Berikut merupakan classification reportnya.

```
=====pemodelan SVM=====
=====CLASSIFICATION REPORT SVM=====
```

	precision	recall	f1-score	support
0	0.82	0.70	0.75	961
1	0.95	0.97	0.96	5187
accuracy			0.93	6148
macro avg	0.88	0.83	0.85	6148
weighted avg	0.92	0.93	0.93	6148

3. Metode LogisticRegression

```
#pemodelan regresi logistik
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import classification_report

# Split the data into training and testing sets
X_train, X_test, y_train, y_test = train_test_split(dense_tfidf_matrix, Sentiment, test_size=0.2, random_state=10)

print("PEMODELAN DENGAN REGRESI LOGISTIK".center(75,"="))
model = LogisticRegression()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)

print('CLASSIFICATION REPORT REGRESI LOGISTIK'.center(75,'='))
print(classification_report(y_test, y_pred))
```

Pada tahap ini, dilakukan splitting data dengan text size = 0.2 dan random state 10. X merupakan skor TF IDF dan y merupakan kolom sentiment yang ditambahkan sebelumnya. Lalu pengklasifikasian menggunakan Metode LogisticRegression. Berikut merupakan classification reportnya.


```

=====PEMODELAN DENGAN REGRESI LOGISTIK=====
=====CLASSIFICATION REPORT REGRESI LOGISTIK=====
              precision    recall  f1-score   support

         0       0.86      0.64      0.73      629
         1       0.94      0.98      0.96     3470

   accuracy          0.93      4099
  macro avg       0.90      0.81      0.85      4099
 weighted avg     0.93      0.93      0.92      4099

```

4. Metode NaiveBayes

```

#pemodelan naive bayes
from sklearn.naive_bayes import GaussianNB
from sklearn.model_selection import train_test_split

# Split the data into training and testing sets
X_train, X_test, y_train, y_test = train_test_split(dense_tfidf_matrix, Sentiment, test_size=0.2, random_state=42)
print("PEMODELAN DENGAN NAIVE BAYES".center(75,"="))
gaussian = GaussianNB()
gaussian.fit(X_train, y_train)
y_pred = gaussian.predict(X_test)
accuracy_nb=round(accuracy_score(y_test,y_pred)* 100, 2)
acc_gaussian = round(gaussian.score(X_train, y_train) * 100, 2)

#perhitungan confusion matrix
print('CLASSIFICATION REPORT NAIVE BAYES'.center(75,'='))
print(classification_report(y_test, y_pred))

```

Pada tahap ini, dilakukan splitting data dengan text size = 0.2 dan random state 42. X merupakan skor TF IDF dan y merupakan kolom sentiment yang ditambahkan sebelumnya. Lalu pengklasifikasian menggunakan Metode Naïve Bayes. Berikut merupakan classification reportnya.

```

=====PEMODELAN DENGAN NAIVE BAYES=====
=====CLASSIFICATION REPORT NAIVE BAYES=====
              precision    recall  f1-score   support

         0       0.18      0.36      0.24      625
         1       0.86      0.71      0.78     3474

   accuracy          0.66      4099
  macro avg       0.52      0.54      0.51      4099
 weighted avg     0.76      0.66      0.70      4099

```

BAB IV

UJI COBA DAN PEMBAHASAN

4.1 Perbandingan Hasil Setiap Percobaan

=====pemodelan SVM=====					=====pemodelan SVM=====					=====pemodelan SVM=====				
=====CLASSIFICATION REPORT SVM=====					=====CLASSIFICATION REPORT SVM=====					=====CLASSIFICATION REPORT SVM=====				
precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support	
0	0.81	0.71	0.76	629	0	0.84	0.66	0.74	629	0	0.82	0.70	0.75	961
1	0.95	0.97	0.96	3470	1	0.94	0.98	0.96	3470	1	0.95	0.97	0.96	5187
accuracy			0.93	4099	accuracy			0.93	4099	accuracy			0.93	6148
macro avg	0.88	0.84	0.86	4099	macro avg	0.89	0.82	0.85	4099	macro avg	0.88	0.83	0.85	6148
weighted avg	0.93	0.93	0.93	4099	weighted avg	0.93	0.93	0.93	4099	weighted avg	0.92	0.93	0.93	6148
Linear					RBF					sigmoid				

a) Metode SVM

Pada percobaan ke (1) dan (2) tidak terdapat perbedaan yang signifikan antara penggunaan metode SVM dengan kernel linear dan RBF. Nilai F1-score sebesar 0.76 dan recall sebesar 0.71 pada kernel linear menunjukkan bahwa kernel linear menghasilkan nilai F1-score dan recall yang lebih tinggi dibandingkan kernel RBF.

b) Metode SVM, Naive Bayes, dan Logistic Regression

=====pemodelan SVM=====					=====PEMODELAN DENGAN NAIVE BAYES=====					=====PEMODELAN DENGAN REGRESI LOGISTIK=====				
=====CLASSIFICATION REPORT SVM=====					=====CLASSIFICATION REPORT NAIVE BAYES=====					=====CLASSIFICATION REPORT REGRESI LOGISTIK=====				
precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support	
0	0.81	0.71	0.76	629	0	0.18	0.36	0.24	625	0	0.86	0.64	0.73	629
1	0.95	0.97	0.96	3470	1	0.86	0.71	0.78	3474	1	0.94	0.98	0.96	3470
accuracy			0.93	4099	accuracy			0.66	4099	accuracy			0.93	4099
macro avg	0.88	0.84	0.86	4099	macro avg	0.52	0.54	0.51	4099	macro avg	0.90	0.81	0.85	4099
weighted avg	0.93	0.93	0.93	4099	weighted avg	0.76	0.66	0.70	4099	weighted avg	0.93	0.93	0.92	4099
SVM					Naïve Bayes					Logistic Regression				

Untuk percobaan ke-2 dengan Naïve Bayes, didapatkan hasil yang paling rendah tingkat akurasi yakni sebesar 0,66. Begitu pula untuk nilai precision, recall, dan f1-scorenya menunjukkan nilai yang cukup rendah dibandingkan dengan percobaan ke-1 dan ke-3.

Namun, percobaan di atas menghasilkan hasil yang kurang tepat. Karena, pada percobaan ke-2 dengan metode Naïve Bayes hasil yang didapatkan sangat rendah dibandingkan dengan percobaan ke-1 dan ke-3.

Hal ini dikarenakan:

1. Adanya random state sebesar 0.10 dan 0.42. Sehingga menghasilkan hasil yang berbeda pula
2. Nilai text size yang sebesar 0.2.

Dari percobaan yang dilakukan, peneliti menemukan masalah saat melakukan percobaan.

4.2 Analisa Masalah

1. Nilai random state dan text size
2. Sehingga setiap percobaan harus kita coba dengan data pembagian data yang berbeda.

Dengan adanya analisa masalah yang ditemukan, maka peneliti membuat solusi yang digunakan untuk permasalahan yang ditemukan.

4.3 Solusi Permasalahan

Melakukan percobaan ulang dengan menggunakan berbagai random state pada metode SVM, Naïve Bayes, dan Logistic Regression sebagai berikut:

Metode	Random State	Akurasi
svm	0	0.93
	10	0.93
	42	0.93
Logistic Regression	0	0.93
	10	0.93
	42	0.93
Naïve Bayes	0	0.67
	10	0.66
	42	0.66

Namun, tidak terlihat perbedaan yang signifikan. Sehingga peneliti memutuskan untuk mencoba ulang dengan menggunakan berbagai text size dan random state pada metode SVM, Naïve Bayes, dan Logistic Regression sebagai berikut:

Metode	Text Size	Random State	Akurasi
SVM	0.1936	0	0.94
		10	0.93
		42	0.93
	0.2	0	0.93
		10	0.93
		42	0.93
	0.25	0	0.93
		10	0.93
		42	0.93
	0.3	0	0.93
		10	0.93
		42	0.93
Logistic Regeression	0.1936	0	0.93
		10	0.93

			42	0.93
		0.2	0	0.93
			10	0.93
			42	0.93
		0.25	0	0.93
			10	0.93
			42	0.93
		0.3	0	0.93
			10	0.93
			42	0.93
	Naïve Bayes	0.1936	0	0.66
			10	0.66
			42	0.66
		0.2	0	0.67
			10	0.66
			42	0.66
		0.25	0	0.67
			10	0.66
			42	0.66
		0.3	0	0.66
			10	0.66
			42	0.66

Dari hasil percobaan di atas, peneliti sudah menemukan hasil yang tepat. Di mana metode SVM dengan random state sebesar 0 dan text size sebesar 0.1936 memiliki tingkat akurasi yang lebih tinggi dibandingkan metode lain.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Model yang saat ini dibuat berhasil memprediksi dengan tingkat akurasi mencapai 0.94 dengan menggunakan metode SVM dengan text size sebesar 0.1936 dan random state sebesar 0.

5.2 Saran

Hal ini sudah cukup baik, namun akan jauh lebih baik lagi apabila digunakan berbagai text size dan random state agar dapat meningkatkan hasil akurasi.

DAFTAR PUSTAKA

- Coletta, L.F.S. et al., 2014. Combining Classification and Clustering for Tweet Sentiment Analysis. In 2014 Brazilian Conference on Intelligent Systems. IEEE, pp. 210–215. Available at: <http://ieeexplore.ieee.org/lpdocs/epic03/wrapper.htm?arnumber=6984832> [Di akses 9 Juni 2024].
- Cvijikj, I.P. & Michahelles, F., 2011. Understanding Social Media Marketing: A Case Study on Topics, Categories and Sentiment on a Facebook Brand Page.
- Gretzel, U., & Yoo, K. H. (2008). Use and impact of online travel reviews. *Information and Communication Technologies in Tourism*, 35–46. Springer, Vienna.
- Haddi, E., Liu, X., & Shi, Y. (2013). The role of text pre-processing in sentiment analysis. *Procedia computer science*, 17, 26-32.
- Indrayuni, E. (2016). Analisa Sentimen Review Hotel Menggunakan Algoritma Support Vector Machine Berbasis Particle Swarm Optimization. *EVOLUSI: Jurnal Sains dan Manajemen*, 4(2).
- Jiang, Y., Shen, Q., Fan, J., & Zhang, X. (2010, October). The classification for e-government document based on SVM. In 2010 International Conference on Web Information Systems and Mining (Vol. 2, pp. 257-260). IEEE.
- Nasukawa, T. & Yi, J., 2003. Sentiment Analysis : Capturing Favorability Using Natural Language Processing. In *Proceedings of the 2nd International Conference on Knowledge Capture*. pp. 70–77.
- Patil, G., Galande, V., Kekan, V., & Dange, K. (2014). Sentiment analysis using support vector machine. *International Journal of Innovative Research in Computer and Communication Engineering*, 2(1), 2607-2612.
- Pranatawijaya, V. H., & Christian, E. (2024). PERBANDINGAN ALGORITMA MACHINE LEARNING UNTUK ANALISIS SENTIMEN PADA ULASAN HOTEL. *Jurnal Teknologi Informasi: Jurnal Keilmuan dan Aplikasi Bidang Teknik Informatika*, 18(1), 35-42.
- Prasojo, M., Sriyanto, S., & Triwidiyanti, J. (2021, September). Prediksi Prestasi Siswa SMK Masuk Pasar Kerja Menggunakan Teknik Data Mining (Studi Kasus SMKN 1 Kota Agung Timur Tanggamus, Lampung). In *Prosiding Seminar Nasional Darmajaya* (Vol. 1, pp. 134-150).